

Entrega Parcial 2

Curso: Data Mining
Alumno: Bustos, Maximiliano Miguel

En esta nueva entrega se realizó un análisis de outliers, generación de nuevos atributos a partir del dataset, y por último, imputación de los datos faltantes con nuevas técnicas aprendidas. Como resultado, se obtuvo una mejora en la predicción del algoritmo.

Filtrado

Previamente al análisis se realiza un filtrado de información, para que los valores de entrenamiento sean congruentes con los valores a predecir.

Generación de nuevos atributos

Atributo **"features"**: Este campo contiene información extra de cada producto. Con el comando *extract* utilizando expresiones regulares, se pudo capturar la siguiente información: baños, dormitorios, superficie, garage.

```
# dormitorios
df_ent.loc[:, "features"].str.extract(r"(\d+) dormitorios;|dormitorio: (\d+);|dormitorios:(\d+);")

# baños
df_ent.loc[:, "features"].str.extract(r"(\d+) baños;|bano: (\d+);|baños:(\d+);")

# garage
df_ent.loc[:, "features"].str.extract(r'(garage);|(cochera):|(cocheras):\d+')

# Superficie
df_ent.loc[:, "features"].str.extract(r";(\d+)\s*m²|scubierta: (\d+);|superficie total:(\d+)m.{1};|sup.\scubierta:(\d+)\s*m²|tcu")
```

Outliers

Se observa outliers en el *precio* de las viviendas. Para esto, se utilizó dos metodologías.
Detección por **rango intercuartil**, el cual muestra una mayor cantidad de valores atípicos en el precio de los departamentos.
Tambien se utilizó un gráfico de **Boxplot** para comparar el precio entre los barrios. En donde se observa *outliers* en *location_2*: Palermo, Capital Federal, Buenos Aires, Villa Crespo y Villa Urquiza principalmente.

```
df_ent.boxplot(by="location_2", column="price", ax=ax1)
```

Imputación

Se realizó las siguientes imputaciones:
Address NA se imputa con "sin info";
description NA se imputa con "sin info";
publication_date reemplazo los NA con la moda "23 nov 2022";
publisher_id NA reemplazo por la moda;
features# Na imputo con "sin info";
location_3 y 4 con "sin info";
source imputo con "sin info";
Imputo cantidad de DORMITORIOS con la moda;
Imputo cantidad BAÑOS con la moda;
Imputo SUPERFICIE con el promedio;
Garage es un booleano. Tiene o no tiene.

Modelo de predicción

Dado que es un modelo de regresión, utiliza valores numéricos para su predicción. Por lo que los nuevos atributos que se adicionaron al dataset, colaboran con el modelo. Y esto se evidencia tanto en el *"análisis de importancia de variables"* y en el resultado del score.